


LỰA CHỌN **MODEL AI** CHO AI AGENT

Không tìm “model tốt nhất”. Hãy thiết kế một hệ thống biết dùng đúng bộ não cho đúng loại công việc — sáng tạo, chiến lược, suy luận sâu hay lặp lại quy mô lớn.

DAVIDTUNG.NET →



Năng suất không đến từ một model mạnh. Nó đến từ một hệ thống phân công thông minh.

ĐỌC TRONG 20 PHÚT · ÁP DỤNG NGAY

Từ “chọn model” đến “thiết kế lực lượng AI”

01 · Vấn đề thật sự	03
02 · Cách chọn trong 5 bước	04
03 · Claude & OpenAI	05
04 · GLM, Kimi, DeepSeek	06
05 · Ma trận chọn model	07
06 · Playbook theo tác vụ	08
07 · Kiến trúc Hermes Agent	09
08 · Lộ trình triển khai	10

5

Nhóm model trọng tâm

Claude, ChatGPT/OpenAI, GLM, Kimi và DeepSeek — nhìn theo vai trò vận hành, không theo bảng xếp hạng.

4

Chế độ công việc

Sáng tạo · Chiến lược · Suy luận sâu · Lặp lại quy mô lớn.

Nguyên tắc: một model có thể làm nhiều việc, nhưng “làm được” không đồng nghĩa “nên giao”. Chọn theo mức rủi ro, độ mơ hồ, chi phí sửa sai và tần suất lặp.

MODEL MẠNH NHẤT VẪN CÓ THỂ LÀ LỰA CHỌN TỆ

Đừng dùng model đắt tiền cho công việc đơn giản.

Nếu dùng model cao cấp cho mọi việc, doanh nghiệp mua sự yên tâm bằng chi phí và độ trễ. Nếu dùng model rẻ cho mọi việc, doanh nghiệp tiết kiệm token nhưng trả bằng rework, sai quyết định và giám sát thủ công.

- Chi phí sửa đầu ra sai
- Thời gian con người kiểm tra
- Độ trễ chuỗi nhiều bước
- Rủi ro công cụ call và dữ liệu

Không phải **giá / triệu token**. Hãy đo **chi phí để hoàn thành một kết quả đạt chuẩn**.



VIỆC LẬP LẠI

VIỆC CHUYÊN MÔN

VIỆC CHIẾN LƯỢC

Quy tắc nâng cấp: chỉ chuyển lên model đắt hơn khi độ mơ hồ, hậu quả sai hoặc yêu cầu tự chủ tăng. Không nâng cấp chỉ vì lời giao việc dài.

Chuẩn hoá 2.000 lead, gắn nhãn ticket, tách trường hoá đơn. Ưu tiên định dạng, tốc độ và thử lại hơn văn phong.

Chọn chiến lược giá, thiết kế tổ chức, duyệt kế hoạch M&A. Ưu tiên giả định, phản biện và người duyệt.

LOW RISK

MEDIUM

HIGH

RA QUYẾT ĐỊNH TRƯỚC KHI GỌI MODEL

Cách chọn trong 5 bước: chọn bộ não theo bản chất tác vụ

01 Tác vụ rõ hay mơ hồ?

Rõ tiêu chí đầu ra → model nhanh/rẻ. Mơ hồ, cần đặt lại vấn đề → model chiến lược.

02 Sai một lần có đắt không?

Nội dung nháp có thể sửa; quyết định giá, pháp lý, bảo mật hay thay đổi vận hành thật cần model mạnh + kiểm tra.

03 Cần sáng tạo hay tính nhất quán?

Sáng tạo cần không gian khám phá. Tác vụ lặp lại cần định dạng, nhiệt độ thấp, eval và thử lại.

04 Cần đọc bao nhiêu ngữ cảnh?

Đừng nhét mọi dữ liệu vào lời giao việc. Long ngữ cảnh hữu ích, nhưng ngữ cảnh càng dài càng cần chọn lọc và chia giai đoạn.

05 Có dùng công cụ và hành động thật không?

Agent gọi công cụ cần tuân thủ format, biết dừng, phục hồi lỗi và không tự ý mở rộng phạm vi.

Model nhanh

Default cho khối lượng cao, rủi ro thấp.

Model chính

Default cho knowledge work và công cụ use.

Model kiểm tra

Chỉ dùng để lập chiến lược, phản biện hoặc duyệt bước rủi ro cao.

Mẫu thực thi: Model nhanh làm phần lớn công việc → model cân bằng xử lý trường hợp khó → model cao cấp hoặc con người duyệt quyết định quan trọng.

LÀM VIỆC KHÓ · QUYẾT ĐỊNH QUAN TRỌNG

Nhóm mạnh nhất: chất lượng cao, giá cao

Claude Opus 5

\$5 vào · \$25 ra / 1 triệu token

CHIẾN LƯỢC

LẬP TRÌNH KHÓ

CÔNG VIỆC DÀI

Nên dùng: lập chiến lược, đọc và sửa hệ thống lớn, tìm lỗi khó, tổng hợp nhiều yêu cầu mâu thuẫn.

Không nên dùng: phân loại dữ liệu, trả lời mẫu, tạo hàng nghìn nội dung giống nhau.

GPT-5.6 Sol

\$5 vào · \$30 ra / 1 triệu token

SUY LUẬN

LẬP TRÌNH

DÙNG CÔNG CỤ

Nên dùng: bài toán nhiều bước, tự thao tác công cụ, làm việc trên dòng lệnh, nhiệm vụ cần độ chính xác cao.

Không nên dùng: công việc đơn giản, khối lượng lớn hoặc cần phản hồi tức thời.

Kimi K3

\$3 vào · \$15 ra / 1 triệu token

Mạnh cho tài liệu rất dài, nghiên cứu, lập trình và chuỗi công việc dài. Giá thấp hơn Opus 5 và Sol nhưng vẫn thuộc nhóm cao cấp.

DeepSeek V4 Pro

\$0,435 vào · \$0,87 ra / 1 triệu token

Giá rất cạnh tranh cho suy luận và lập trình. Phù hợp làm bộ não chính khi doanh nghiệp muốn giảm mạnh chi phí.

Nếu một quyết định sai có thể làm mất nhiều giờ hoặc ảnh hưởng khách hàng, hãy trả tiền cho model mạnh.

CHỌN THEO CHẤT LƯỢNG VÀ CHI PHÍ

Cùng một phân khúc, có nhiều lựa chọn thay thế

CAO CẤP	Claude Fable 5 · Claude Opus 5 · GPT-5.6 Sol · Kimi K3 Fable 5 là mức mạnh nhất phát hành rộng rãi của Claude; Opus 5 và Sol thực dụng hơn cho việc khó; Kimi K3 nổi bật khi cần đầu ra rất dài.	CHẤT LƯỢNG TRƯỚC
CÂN BẰNG	Claude Sonnet 5 · GPT-5.6 Terra · GLM 5.2 · DeepSeek V4 Pro Công việc hằng ngày, viết, phân tích, lập trình và dùng công cụ.	MẠC ĐỊNH TỐT
NHANH & RẺ	Claude Haiku 4.5 · GPT-5.6 Luna · DeepSeek V4 Flash · GLM Flash Phân loại, tóm tắt, trả lời mẫu, xử lý số lượng lớn. Luna và V4 Flash tiết kiệm hơn Haiku 4.5.	KHỐI LƯỢNG LỚN

GLM 5.2 \$1,40 · \$4,40 Bộ não cân bằng có giá thấp. Hợp lập trình dự án, chuỗi công việc dài và gọi nhiều công cụ.	GPT-5.6 Luna \$0,20 · \$1,20 Phản hồi nhanh, chi phí thấp. Hợp trò chuyện, phân loại và bước phụ trong Trợ lý AI.	V4 Flash \$0,14 · \$0,28 Rẻ nhất ở đầu ra trong nhóm so sánh. Hợp công việc lặp lại và phản hồi nhanh.
---	---	--

Cách hiểu tên: “Opus / Sol” thường là dòng cao cấp; “Sonnet / Terra” là dòng cân bằng; “Luna / Flash” là dòng nhanh và tiết kiệm. Tên khác nhau nhưng vai trò gần giống nhau.

TÊN CỤ THỂ · VIỆC CỤ THỂ

Chọn model nào cho từng loại công việc?

CÔNG VIỆC	LỰA CHỌN CHÍNH	LỰA CHỌN TIẾT KIỆM	KHI NÀO DÙNG MODEL CAO CẤP?
Chiến lược, đề xuất cho CEO	Opus 5 / Sol	Sonnet 5 / Terra / V4 Pro	Khi quyết định khó sửa lại
Ý tưởng, nội dung sáng tạo	Sonnet 5 / Terra	GLM 5.2	Khi cần hướng đi thật khác biệt
Lập trình hệ thống lớn	Opus 5 / Sol / Kimi K3	GLM 5.2 / V4 Pro	Khi sửa kiến trúc hoặc dữ liệu thật
Nghiên cứu nhiều tài liệu	Kimi K3	GLM 5.2 / V4 Pro	Khi nguồn mâu thuẫn cần kết luận
Toán, logic, suy luận	Sol / V4 Pro	GLM 5.2	Khi kết quả ảnh hưởng tiến hoặc an toàn
Tóm tắt, phân loại số lượng lớn	Luna / V4 Flash	GLM Flash	Chỉ nâng khi kết quả không đạt chuẩn
Trợ lý AI gọi công cụ	Terra / Sonnet 5 / GLM 5.2	Luna cho bước phụ	Khi công cụ có thể xóa, gửi hoặc thanh toán
Kiểm tra và phản biện	Dùng hãng khác với model tạo bản nháp	Luật kiểm tra tự động	Khi hai model không thống nhất

● Dùng thường xuyên

Sonnet 5, Terra, GLM 5.2 hoặc V4 Pro.

● Xử lý số lượng lớn

Luna, V4 Flash hoặc GLM Flash.

● Việc quan trọng

Opus 5, Sol, Kimi K3 và người duyệt.

Mẹo dễ nhớ: bắt đầu bằng model cân bằng. Nếu không đạt thì nâng lên dòng cao cấp; nếu ổn định và lặp lại nhiều thì hạ xuống dòng nhanh, rẻ.

4 CHẾ ĐỘ VẬN HÀNH

Khi nào cần sáng tạo, chiến lược, suy luận và lặp lại?

01 · SÁNG TẠO

Model: Claude / OpenAI.

Cách giao việc: mở rộng trước, hội tụ sau. Yêu cầu 3–5 hướng khác biệt, không chỉ biến thể câu chữ.

Quy trình: model A tạo → con người chọn tiêu chí → model B phát triển/đánh giá.

02 · CHIẾN LƯỢC

Model: Opus 5 hoặc Sol; dùng DeepSeek V4 Pro để phản biện.

Cách giao việc: mục tiêu, ràng buộc, giả định, đánh đổi, điều gì sẽ làm thay đổi quyết định.

Quy trình: draft → phản biện → quyết định → decision log.

03 · SUY LUẬN SÂU

Model: Sol hoặc DeepSeek V4 Pro; Claude kiểm tra cách diễn giải.

Cách giao việc: cho phép công cụ tính toán và kiểm chứng; không yêu cầu “show chain-of-thought”.

Quy trình: solve → verify độc lập → chỉ xuất kết luận và bằng chứng.

04 · LẶP LẠI QUY MÔ LỚN

Model: Luna, DeepSeek V4 Flash hoặc GLM Flash; đổi model khi độ tin cậy thấp.

Cách giao việc: JSON định dạng, examples, temperature thấp, giới hạn output.

Quy trình: số lượng lớn nhỏ → eval → thử lại → dead-letter queue.

Sáng tạo cần độ rộng. Chiến lược cần chiều sâu. Lặp lại cần kỷ luật.

LÀM BẢN NHÁP

Model tối ưu cho loại công việc



KIỂM TRA

Quy tắc, kiểm thử, nguồn, định dạng



NÂNG MODEL

Model mạnh hơn hoặc con người

MỘT LỚP ĐIỀU PHỐI · NHIỀU BỘ NÃO

Kết hợp cùng Hermes Agent: model trở thành tài nguyên có thể định tuyến

Thiết lập / đổi nhà cung cấp

`hermes model`

Chạy trực tiếp từng họ model

`hermes chat --nhà cung cấp anthropic --model <claude>``hermes chat --nhà cung cấp openai-api --model <gpt>``hermes chat --nhà cung cấp zai --model <glm>``hermes chat --nhà cung cấp kimi-lập trình --model <kimi>``hermes chat --nhà cung cấp deepseek --model <deepseek>`

✓ Có thể dùng địa chỉ kết nối riêng, OpenRouter, Nous Portal và model dự phòng.

Không đưa khóa truy cập vào cẩm nang, lời giao việc hay kho mã nguồn. Hermes lưu secret trong môi trường/config phù hợp; kiểm tra docs của nhà cung cấp trước vận hành thật.

1 • Model chính

Giữ hội thoại, hiểu mục tiêu, quyết định route.

2 • Model phụ

Đọc hình ảnh, tóm tắt nội dung trên mạng hoặc tác vụ phụ có thể dùng model nhanh/rẻ riêng.

3 • Trợ lý con

Phân nhánh research, lập trình và QA song song trong phạm vi thông tin riêng.

4 • Fallback

Chuyển nhà cung cấp khi giới hạn lượt gọi, lỗi endpoint hoặc model không phù hợp.

5 • Bộ nhớ và kỹ năng

Giữ quy trình, tiêu chuẩn và bài học — model thay đổi nhưng cách làm không mất.

TỪ THỬ NGHIỆM ĐẾN VẬN HÀNH THẬT

Đừng triển khai “đa model” cùng lúc. Xây cách điều phối từ dữ liệu thật.

Tuần 1 • Chọn 20 tác vụ thật

Phân nhóm theo sáng tạo, chiến lược, suy luận, xử lý số lượng lớn. Lưu dữ liệu đầu vào và kết quả chuẩn và tiêu chí chấp nhận.

Tuần 2 • Benchmark 3 vai trò

Nhanh · Cân bằng · Cao cấp. So sánh chất lượng, tốc độ, chi phí và thời gian sửa — không chỉ dựa vào cảm giác.

Tuần 3 • Gắn router + eval

Bắt đầu bằng quy tắc rõ ràng. Chỉ nâng model khi độ tin cậy thấp, công cụ lỗi hoặc kết quả không đạt kiểm tra.

Tuần 4 • Production guardrails

Giới hạn chi phí, thời gian chờ, thử lại, model dự phòng, nhật ký, người phê duyệt và bảng theo dõi chi phí cho một kết quả đạt yêu cầu.

80/15/5

Tỷ lệ khởi đầu để xuất

80% model nhanh hoặc cân bằng · 15% nâng model · 5% model cao cấp hoặc người duyệt. Điều chỉnh bằng dữ liệu eval.

Dashboard tối thiểu

- Tỷ lệ đạt yêu cầu theo công việc/model
- Thời gian phản hồi thường gặp/chậm nhất
- Chi phí cho output đạt chuẩn
- Tỷ lệ phải nâng model hoặc đổi dự phòng
- Số phút con người sửa
- Lỗi công cụ / hành động nguy hiểm

Công tắc đổi nhanh: nếu model thay đổi hành vi sau update, router phải cho phép chuyển model ngay mà không sửa workflow nghiệp vụ.

Model giống như nhân sự thuê theo lượt. Bộ kiểm tra là cách quản lý chất lượng.

MỘT TRANG ĐỂ DỪNG HÀNG NGÀY

Nếu chỉ nhớ 7 điều

01 Không có model tốt nhất cho mọi tác vụ.

Chỉ có model phù hợp nhất với rủi ro, độ mơ hồ và tần suất hiện tại.

02 Dùng model rẻ nhất đạt chuẩn — không phải model rẻ nhất.

Đưa chi phí kiểm tra và sửa sai vào phép tính.

03 Sáng tạo và chiến lược cần workflow khác nhau.

Sáng tạo mở rộng rồi hội tụ; chiến lược phải làm rõ giả định và đánh đổi.

04 Khả năng đọc tài liệu dài không thay thế việc chọn lọc thông tin.

Chọn lọc, tóm tắt, phân đoạn và truy xuất đúng lúc.

05 Xử lý số lượng lớn cần định dạng rõ, kiểm tra và thử lại.

Lời giao việc hay không đủ để vận hành hàng nghìn lượt ổn định.

06 Dùng khác họ model để phản biện.

Giảm lỗi tương quan, nhưng chỉ áp dụng ở quyết định có giá trị cao.

07 Hermes giữ hệ thống ổn định khi model thay đổi.

Điều phối nhà cung cấp, model dự phòng, trợ lý con, công cụ, bộ nhớ và kỹ năng tách năng lực vận hành khỏi một nhà cung cấp.

Quyết định ngay hôm nay: chọn một tác vụ lặp lại tốn nhiều giờ nhất, tạo bộ 20 ví dụ thật, so sánh nhóm Nhanh/Cần bằng/Cao cấp và đo “chi phí cho một kết quả đạt yêu cầu”.

NGUỒN CHÍNH THỨC · TRUY XUẤT 08/08/2026

Nguồn tham khảo chính thức

Anthropic / Claude

docs.anthropic.com/en/docs/about-claude/models/overview.md
docs.anthropic.com/en/docs/build-with-claude/ngữ-cảnh-windows.md

Kimi / Moonshot

platform.moonshot.ai/docs
platform.kimi.ai — tài liệu nền tảng chính thức về khả năng đọc tài liệu dài và gọi công cụ.

OpenAI

developers.openai.com/api/docs/models
developers.openai.com/api/docs/guides/reasoning
developers.openai.com/api/docs/guides/function-calling

DeepSeek

api-docs.deepseek.com — model, giá, chế độ suy luận, gọi công cụ và bộ nhớ đệm.

Z.AI / GLM

docs.z.ai/lms.txt
docs.z.ai/guides/overview/pricing.md

Giá và tên model cụ thể

openrouter.ai/api/v1/models — danh mục model, giá theo 1 triệu token, độ dài tài liệu hỗ trợ và mô tả phân khúc tại thời điểm truy xuất.

Hermes Agent

hermes-agent.nousresearch.com/docs/integrations/providers
github.com/NousResearch/hermes-agent

Danh mục model, giá và khả năng thay đổi nhanh. Trước khi ký SLA hoặc tối ưu ngân sách, kiểm tra lại tài liệu chính thức và chạy eval trên dữ liệu của chính bạn.

Không xác minh độc lập: cẩm nang không tuyên bố một model luôn “thắng” model khác, không dùng so sánh thử marketing làm kết luận tuyệt đối và không đưa giá token chi tiết vào ma trận vận hành vì giá/version biến động nhanh.

BIẾN KIẾN THỨC THÀNH HỆ THỐNG AI THỰC CHIẾN

Xây Hermes Agent cho chính doanh nghiệp của bạn.

Tham gia chương trình huấn luyện cùng David Tung để thiết kế, triển khai và vận hành đội ngũ AI Agent theo công việc thật.

KHÁM PHÁ CHƯƠNG TRÌNH → DAVIDTUNG.NET/HERMES